

APP DETECCIÓN PROD

Entregable final · Planificación, generación y auditoría E2E con Playwright

Dato	Detalle
Equipo / producto	App Detección Prod
Integrante	Gina Fabiana Villanueva Viscarra
IDE / agente	Visual Studio Code + GitHub Copilot/Agent; Playwright Test Planner y Playwright Test Generator mediante MCP Server
Modelo observado en las sesiones	GPT-5.6 Luna
Repositorio	github.com/ginavillanueva/App-Deteccion-Prod-M4/tree/modulo-bpmn-workflow-engine
Fecha de cierre	11 de septiembre de 2026

RESULTADO GLOBAL

24/24 casos E2E oficiales implementados y ejecutados en una misma corrida. Resultado final: 24 passed, 0 failed, Chromium, 1 worker, 0 retries, 2.7 min.

1. Resumen ejecutivo

Se construyó una suite E2E completa para App Detección Prod siguiendo un flujo Planner → Generator → auditoría → corrección → estabilización. El inventario oficial contiene 24 casos y los 24 quedaron automatizados. La validación final ejecutó los 24 en conjunto sobre Chromium con un único worker y sin retries, obteniendo 24 passed en 2.7 minutos.

La estrategia priorizó tests independientes, localizadores semánticos, control explícito del Thread ID, assertions web-first y expect.poll para absorber rerenders de Streamlit. Se evitó usar sleeps/waitForTimeout y no se hardcodearon IDs dinámicos. Los errores intermedios se conservaron como evidencia de auditoría y se corrigieron únicamente en el test afectado.

Reglas de negocio preservadas

CAMBIO_PRECIO se validó como consulta informativa y trazable, sin aprobación ni modificación automática. ACCION_COMERCIAL se validó como consulta de registros sin ejecución autónoma. PROMPT_INJECTION se validó como guardrail con cero tools ejecutadas.

2. Metodología y criterio de auditoría

Cada test generado se auditó contra cinco preguntas. En la tabla de auditoría, “Pregunta que falló” identifica la dimensión que motivó una corrección; “Ninguna” significa que el test fue aceptado sin cambios funcionales posteriores.

ID	Pregunta de auditoría
P1	¿El test cubre exactamente el caso del plan y un flujo real de la UI?
P2	¿Es independiente y controla su estado/thread sin depender de otro test?
P3	¿Usa localizadores estables y semánticos, sin refs/IDs dinámicos?
P4	¿Sincroniza correctamente rerenders/asincronía sin sleeps ni esperas fijas?
P5	¿La aserción valida el resultado observable y la regla de negocio, sin sobreajustarse a texto accesorio?

3. Inventario completo de flujos y test que los cubre

Caso	Flujo / comportamiento	Test
NAV-01	Encabezado y salud del sistema	tests/e2e/nav-01.spec.ts
THR-01	Nuevo thread cambia el Thread ID activo	tests/e2e/thr-01.spec.ts
CTX-01	Departamento, cadena y sala reflejan la sala empresarial	tests/e2e/ctx-01.spec.ts
PRD-01	Seleccionar producto muestra producto y clasificación asociada	tests/e2e/prd-01.spec.ts
SRC-01	Cambiar la fuente backend deja visible la selección antes de ejecutar	tests/e2e/src-01.spec.ts
NOTE-01	Nota operativa sin reemplazar la pregunta principal	tests/e2e/note-01.spec.ts
OPE-01	Thread nuevo sin ejecutar queda en NO_EXISTE	tests/e2e/ope-01.spec.ts

Caso	Flujo / comportamiento	Test
OPE-02	Vencimiento finaliza con evidencia de detalle	tests/e2e/ope-02.spec.ts
OPE-03	Cambio de precio es consulta informativa trazable	tests/e2e/ope-03.spec.ts
OPE-04	Acción comercial consulta registros sin ejecución autónoma	tests/e2e/ope-04.spec.ts
OPE-05	Auditoría completa se pausa y conserva checkpoint/NEXT	tests/e2e/ope-05.spec.ts
OPE-06	Reanudación desde SQLite/checkpoint	tests/e2e/ope-06.spec.ts
OPE-07	Recuperación conserva estado persistido sin reejecutar MCP	tests/e2e/ope-07.spec.ts
OPE-08	Prompt injection se detiene en el guardrail	tests/e2e/ope-08.spec.ts
EVI-01	Subir audio y confirmar transcripción	tests/e2e/evi-01.spec.ts
EVI-02	Subir imagen y confirmar descripción	tests/e2e/evi-02.spec.ts
EVI-03	Activar cámara y verificar captura disponible	tests/e2e/evi-03.spec.ts
TRZ-01	Abrir trazabilidad en thread nuevo	tests/e2e/trz-01.spec.ts
TRZ-02	Abrir trazabilidad después de ejecutar	tests/e2e/trz-02.spec.ts
GRA-01	Abrir grafo generado y arquitectura defendible	tests/e2e/gra-01.spec.ts
GRA-02	Workflow BPMN animado muestra avance y finalización	tests/e2e/gra-02.spec.ts
GRA-03	Simular incidente: incidente, rework y cierre controlado	tests/e2e/gra-03.spec.ts
GRA-04	Reiniciar visualización restaura estado inicial y limpia bitácora	tests/e2e/gra-04.spec.ts
GUI-01	Abrir guion de defensa	tests/e2e/gui-01.spec.ts

4. Tabla de auditoría test por test

Veredictos: Aceptado = pasó la auditoría sin corrección funcional posterior; Corregido = se ajustó el test y luego fue aceptado; Descartado = no forma parte de la suite final. No hubo descartes.

Caso	Plan	Archivo	Veredicto	Pregunta	Qué se cambió / decisión
NAV-01	PLAN_01	nav-01.spec.ts	Aceptado	Ninguna	Roles de heading y texto visible; sin ajuste posterior.
THR-01	PLAN_01	thr-01.spec.ts	Aceptado	Ninguna	Thread ID leído antes/después y comparación dinámica; no se hardcodeó el valor.
CTX-01	PLAN_02	ctx-01.spec.ts	Corregido	P3	Combobox Streamlit validado por nombre accesible/aria-label, no por value dinámico.
PRD-01	PLAN_02	prd-01.spec.ts	Corregido	P3	Selección de producto ajustada a roles/opciones accesibles tras rerender.
SRC-01	PLAN_02	src-01.spec.ts	Corregido	P3	Radio nativo oculto: se interactuó mediante rol/label observable.
NOTE-01	PLAN_02	note-01.spec.ts	Aceptado	Ninguna	Se verificó que la nota queda en evidencia sin sustituir la pregunta principal.
OPE-01	PLAN_03A	ope-01.spec.ts	Aceptado	Ninguna	Thread nuevo y estado NO_EXISTE observables.
OPE-02	PLAN_03A	ope-02.spec.ts	Corregido	P4	Sincronización del escenario y evidencia de detalle con assertions web-first.
OPE-03	PLAN_03A	ope-03.spec.ts	Corregido	P4	Fallo global por rerender: se añadió toBeEnabled() antes de pulsar EJECUTAR. Quedó 3/3 y 4/4.
OPE-04	PLAN_03A	ope-04.spec.ts	Corregido	P4	Se estabilizó la observación de FINALIZADO y evidencia de consulta sin ejecución autónoma.
OPE-05	PLAN_04	ope-05.spec.ts	Corregido	P4	Se ajustó texto real "Este thread está PAUSADO" y espera de pregunta precargada antes de pausar.
OPE-06	PLAN_04	ope-06.spec.ts	Corregido	P4	Sincronización previa a PAUSAR y validación de reanudación desde SQLite/checkpoint.
OPE-07	PLAN_04	ope-07.spec.ts	Corregido	P4	Se añadió espera web-first del workflow reanudado antes de comprobar FINALIZADO.
OPE-08	PLAN_04	ope-08.spec.ts	Corregido	P5	Se eliminaron aserciones textuales redundantes; se mantuvo PROMPT_INJECTION + cero tools. 5/5 estable.
EVI-01	PLAN_05	evi-01.spec.ts	Aceptado	Ninguna	Upload con fixture reproducible y setInputFiles; 2/2 estable.
EVI-02	PLAN_05	evi-02.spec.ts	Aceptado	Ninguna	Upload de imagen con fixture local reproducible; 2/2 estable.
EVI-03	PLAN_05	evi-03.spec.ts	Aceptado	Ninguna	Permiso de cámara + dispositivo/fichero de video falso Chromium; 2/2 estable.
TRZ-01	PLAN_06	trz-01.spec.ts	Corregido	P3	Estados acotados a alert y selects por aria-label; IDs dinámicos no usados como selector.
TRZ-02	PLAN_06	trz-02.spec.ts	Corregido	P4	Polling/espera acotada para trazabilidad posterior a ejecución y rerenders.

Caso	Plan	Archivo	Veredicto	Pregunta	Qué se cambió / decisión
GRA-01	PLAN_07	gra-01.spec.ts	Corregido	P5	Validación de tokens/elementos del bloque Mermaid observable, sin depender del texto completo.
GRA-02	PLAN_07	gra-02.spec.ts	Corregido	P4	Se sustituyó espera indefinida por expect.poll con timeout acotado para animación BPMN.
GRA-03	PLAN_07	gra-03.spec.ts	Corregido	P5	Coincidencias ajustadas a mensajes compuestos reales de incidente/rework/cierre.
GRA-04	PLAN_07	gra-04.spec.ts	Aceptado	Ninguna	Reinicio y limpieza observable; 2/2 estable dentro del bloque.
GUI-01	PLAN_08	gui-01.spec.ts	Corregido	P5	Aserción del listado ajustada para validar textos completos observables; 2/2 estable.

Totales consolidados

Casos propuestos por Planner: 24. Tests finales del Generator: 24. Aceptados sin corrección funcional posterior: 8. Corregidos y aceptados: 16. Descartados: 0. Suite final: 24/24 passed.

5. Anclas agregadas / utilizadas para automatización

La estrategia evitó “test IDs por todas partes”. Se añadió/confirmó una ancla explícita para el dato de sesión y el resto se resolvió preferentemente mediante accesibilidad existente.

Tipo	Ancla	Pantalla / uso	Estado
data-testid	thread-id	Panel lateral “Control”; lectura del Thread ID antes/después de Nuevo thread y asociación de trazabilidad	Agregada/confirmada y usada
Rol + nombre accesible	button: Nuevo thread, EJECUTAR, PAUSAR, REANUDAR, RECUPERAR	Control y ejecución de workflow	Existente, reutilizada
Rol + aria-label	combobox: Departamento, Cadena, Sala, Escenario	Contexto empresarial y selección de caso	Existente, reutilizada
Rol	tab / tabpanel	Trazabilidad, Grafo/arquitectura y Guion de defensa	Existente, reutilizada
iframe estable	iframe[title="st.iframe"] / frameLocator	Visualización BPMN	Existente, reutilizada




Figura 1. Ancla de sesión: Thread ID y control “Nuevo thread”.

6. Evidencia de ejecución y estabilidad

Las siguientes capturas están anotadas sobre la propia imagen, tal como exige la consigna. Se incluyen evidencias de estabilización, la corrida global en terminal y el reporte HTML de Playwright de esa misma corrida. El archivo photoss.docx conserva además el historial visual de iteraciones y fallos intermedios.




Figura 2. Auditoría/corrección de OPE-03: sincronización del botón EJECUTAR tras rerender.




Figura 3. Evidencia multimodal: EVI-01 a EVI-03, 6 passed con dos repeticiones.




Figura 4. Trazabilidad: TRZ-01 y TRZ-02 estabilizados.




Figura 5. Grafo/arquitectura: GRA-01 a GRA-04, 8 passed.




Figura 6. GUI-01, último caso oficial: 2 passed, 0 failed.




Figura 7. Corrida global definitiva: 24 passed en 2.7 min, suite completa en verde.

EVIDENCIA HTML INCORPORADA

Se incorporaron capturas anotadas del reporte HTML de Playwright correspondiente a la misma corrida global de 24 tests. El encabezado del reporte muestra Project: chromium, All 24, Passed 24, Failed 0 y Total time: 2.7m. Las capturas consecutivas documentan además la lista de tests del reporte con estado verde.

6.1 Reporte HTML Playwright de la misma corrida global

Las Figuras 8 a 12 corresponden al reporte HTML generado por la misma ejecución global mostrada en la terminal. **La cabecera del reporte confirma All 24, Passed 24, Failed 0, Project: chromium y Total time: 2.7m.** Las capturas siguientes recorren la lista del reporte y evidencian los tests en estado verde.




Figura 8. Reporte HTML de la corrida global: All 24, Passed 24, Failed 0, Chromium y 2.7 min.




Figura 9. Reporte HTML · lista de tests, continuación 1/4.

✓ Contexto, producto, fuente y nota · NOTE-01 · Conservar nota operativa sin reem	
note-01.spec.ts:7	
✓ ope-01.spec.ts	
✓ Operacion basica OPE-01 a OPE-04 · OPE-01 · Thread nuevo sin ejecutar queda en NO_EXISTE	2.2s
ope-01.spec.ts:4	chromium
✓ ope-02.spec.ts	
✓ Operacion basica OPE-01 a OPE-04 · OPE-02 · Vencimiento finaliza con evidencia de detalle	5.4s
ope-02.spec.ts:5	chromium
✓ ope-03.spec.ts	
✓ Operacion basica OPE-01 a OPE-04 · OPE-03 · Cambio de precio es consulta informativa trazable	5.8s
ope-03.spec.ts:5	chromium
✓ ope-04.spec.ts	
✓ Operacion basica OPE-01 a OPE-04 · OPE-04 · Accion comercial consulta registros sin ejecucion autonoma	5.7s
ope-04.spec.ts:5	chromium
✓ ope-05.spec.ts	
✓ Operacion y workflow OPE-05 · OPE-05 · Auditoria completa se pausa antes de cambios de precio	5.7s
ope-05.spec.ts:4	chromium
✓ ope-06.spec.ts	
✓ Operacion y workflow OPE-06 · OPE-06 · Auditoria completa se reanuda desde checkpoint	9.8s
ope-06.spec.ts:4	chromium

Figura 10. Reporte HTML · lista de tests, continuación 2/4.

✓ Operacion y workflow OPE-06 · OPE-06 · Auditoria completa se reanuda desde cl	
ope-06.spec.ts:4	
✓ ope-07.spec.ts	
✓ Operacion y workflow OPE-07 · OPE-07 · Recuperar conserva el estado persistido sin reejecutar MCP	11.0s
ope-07.spec.ts:4	chromium
✓ ope-08.spec.ts	
✓ Operacion y workflow OPE-08 · OPE-08 · Prompt injection se detiene en el guardrail	4.3s
ope-08.spec.ts:4	chromium
✓ prd-01.spec.ts	
✓ Contexto, producto, fuente y nota · PRD-01 · Seleccionar producto muestra producto y clasificacion asociada	2.9s
prd-01.spec.ts:7	chromium
✓ src-01.spec.ts	
✓ Contexto, producto, fuente y nota · SRC-01 · Cambiar la fuente backend deja visible la seleccion antes de ejecutar	2.6s
src-01.spec.ts:7	chromium
✓ thr-01.spec.ts	
✓ Navegacion y sesion · THR-01 · Nuevo thread cambia el Thread ID activo	2.5s
thr-01.spec.ts:7	chromium
✓ trz-01.spec.ts	
✓ Trazabilidad · TRZ-01 · abrir Trazabilidad en thread nuevo	3.3s
trz-01.spec.ts:4	chromium

Figura 11. Reporte HTML · lista de tests, continuación 3/4.




Figura 12. Reporte HTML · lista de tests, continuación 4/4; incluye el cierre de Trazabilidad.

7. Tokens del Planner y Generator

Las sesiones registradas muestran explícitamente “tokens no expuestos por la interfaz”. La interfaz sí muestra créditos/contexto de sesión en algunos momentos, pero esos valores no equivalen a tokens de entrada y salida. Para evitar inventar métricas, el entregable reporta N/D cuando la herramienta no expone el dato.

Métrica solicitada	Resultado documentado	Observación
Tokens de entrada del Planner	N/D — no expuestos por la interfaz	Se trabajó en 8 bloques de plan (PLAN_01 a PLAN_08).
Tokens de salida del Planner	N/D — no expuestos por la interfaz	Los cierres de Planner consignaron literalmente “tokens no expuestos por la interfaz”.
Tokens del Generator	N/D — no expuestos por la interfaz	No existe contador input/output visible y confiable en las capturas.
Promedio por test del Generator	No calculable con evidencia disponible	24 tests generados; sin total de tokens no se puede dividir de forma válida.

Cómo cerrar este punto si el docente exige número

Si el IDE/plugin ofrece exportación de uso por sesión, registrar input_tokens y output_tokens de cada sesión Planner/Generator y calcular: promedio Generator = (tokens entrada + salida de sesiones Generator) / 24. No usar “créditos” como sustituto de tokens.

8. Qué no se evaluó como E2E y pasa a evals

Aspecto	Qué sí cubre E2E	Qué queda para evals / manual	Motivo
Calidad de transcripción de audio	Upload, procesamiento y resultado visible	Exactitud semántica/word error rate de la transcripción	Salida probabilística; requiere corpus y métrica de calidad.
Calidad de descripción de imagen	Upload y descripción visible	Fidelidad, cobertura y alucinaciones de la descripción	No debe validarse con igualdad exacta de texto generativo.
Cámara real en hardware diverso	Flujo de permiso/captura con dispositivo de video falso Chromium	Compatibilidad con cámaras físicas, drivers y permisos del SO	Dependencia de hardware/entorno fuera del navegador controlado.

Aspecto	Qué sí cubre E2E	Qué queda para evals / manual	Motivo
Robustez amplia ante prompt injection	Caso OPE-08 con PROMPT_INJECTION y cero tools	Cobertura adversarial con muchas variantes de ataque	Un E2E verifica el flujo; la robustez requiere set de evals.
Calidad lingüística de respuestas LLM	Estados y evidencias determinísticas de UI/workflow	Relevancia, claridad, exactitud factual y consistencia de respuestas generativas	Criterios probabilísticos, mejor medidos con evals.
Consumo real de tokens	No cubierto	Telemetría de input/output y costo por caso	La interfaz usada no expone los contadores requeridos.

9. Resultado final y reproducibilidad

Indicador	Resultado
Casos oficiales del inventario	24
Tests E2E finales	24
Aprobados en corrida global	24
Fallidos en corrida global	0
Browser	Chromium
Workers	1
Retries	0
Tiempo corrida final	2.7 min
Resultado	SUITE E2E COMPLETA Y VALIDADA
Reporte HTML de la misma corrida	All 24 · Passed 24 · Failed 0 · Chromium · 2.7 min

Comando equivalente de cierre (paths explícitos de los 24 specs): ejecutar Playwright con --project=chromium --workers=1 --retries=0 --reporter=list. Los bloques también se validaron con repeat-each=2 y, en casos frágiles, con repeticiones adicionales antes del cierre global.

10. Archivos a entregar junto con este documento

Elemento	Entrega recomendada
Documento	Este archivo .docx (o su PDF si se exporta).
Código	Carpetas tests/ y specs/ comprimidas en .zip, o enlace al repositorio.
Repositorio	github.com/ginavillanueva/App-Deteccion-Prod-M4/tree/modulo-bpmn-workflow-engine
Evidencia adicional obligatoria	Incluida: terminal global 24 passed y reporte HTML Playwright de la misma corrida, ambos anotados sobre la captura.

11. Checklist de cumplimiento

Requisito	Estado
Equipo y producto; integrante; agente/IDE/modelo	Cumplido
Inventario completo + test que cubre cada flujo	Cumplido
Tabla de auditoría por test + totales Planner/Generator	Cumplido
Anclas agregadas/empleadas y pantalla	Cumplido
Captura terminal suite completa verde, anotada	Cumplido
Captura HTML Playwright misma corrida, anotada	Cumplido — All 24 / Passed 24 / Failed 0 / 2.7 min
Tokens Planner/Generator	Reportado como N/D: no expuestos por interfaz
Qué no se pudo probar E2E y por qué	Cumplido
tests/ + specs/ zip o enlace repo	Enlace repo incluido; adjuntar ZIP si se prefiere

Cierre

La evidencia consolidada demuestra 24/24 tests E2E implementados y aprobados en una misma corrida global: 24 passed, 0 failed, Chromium, 1 worker, 0 retries, 2.7 min. También se incorporó el reporte HTML de esa misma corrida con All 24, Passed 24 y Failed 0, junto con capturas consecutivas de la lista de tests. El paquete documental queda alineado con la consigna; la única métrica reportada como N/D son los tokens de entrada/salida, porque la interfaz utilizada no expuso contadores verificables y no se inventaron valores.